

Detección de Fatiga Muscular mediante sEMG: Análisis Comparativo de Enfoques Binarios y Multiclasificación en Modelos de Machine Learning



UNIVERSIDAD PERUANA
CAYETANO HEREDIA

Autores: Cárdenas Infantes, B. A.; Carrascal Castillo, D. A.; Navarro Luyo, K. R.

OBJETIVO

Evaluar y comparar el rendimiento de distintos algoritmos de Machine Learning (XGBoost, SVM, etc) bajo enfoques de clasificación binaria y multiclasificación, para determinar la estrategia más eficaz en la detección automática de fatiga muscular mediante señales sEMG.

INTRODUCCIÓN

Fatiga muscular

1.7 Billones de afectados de lesiones musculoesqueléticas en el mundo [1] son la **3^a causa más frecuente de consulta médica traumatólogica** [2]



45% de los trabajadores en Perú reporta dolor específico en hombros [3]

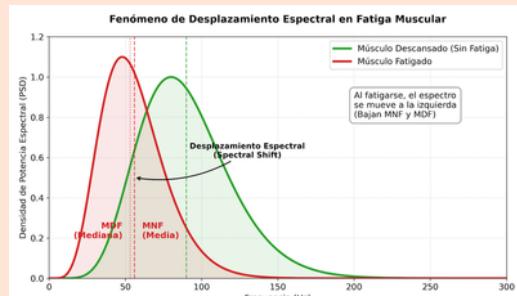


PROBLEMÁTICA

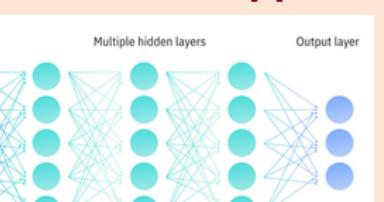
Actualmente, la detección se basa en evaluaciones subjetivas como el dolor o el cansancio, que son **poco fiables** y a menudo no reflejan el estado fisiológico real del músculo.

ESTADO DEL ARTE

Análisis espectral [4]



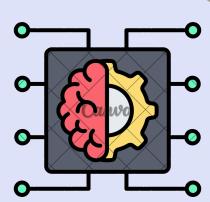
DEEP LEARNING [5]



- CNN: detectan patrones en ventanas sEMG
- LSTM / CNN-LSTM: capturan dependencias temporales
- Autoencoders: representación sin etiquetas

PROUESTA SOLUCIÓN

Desarrollar una herramienta de Machine Learning para la **detección temprana de fatiga** en hombro y brazo y así prevenir lesiones musculoesqueléticas.

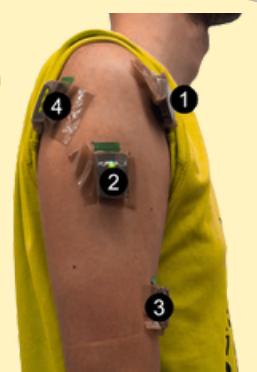


MATERIALES

Año de publicación: 2024

Base de datos: Zenodo (*A Dataset of sEMG and Self-Perceived Fatigue Levels for Muscle Fatigue Analysis*)

- Población: 13 participantes adultos sanos.
- Actividad: Realizar 12 movimientos dinámicos del tren superior hasta sentirse cansados
- Frecuencia de muestreo sEMG: 1,259 Hz
- Frecuencia índice de fatiga: 50 Hz (intervalo 20 ms)
- Músculos Objetivo: Bíceps y Deltoides (Anterior, Medio, Posterior).
- 3 Niveles de fatiga: 0 = Sin fatiga, 1 = Fatiga media, 2 = Fatiga alta



METODOLOGÍA

Preprocesamiento de la Señal

Filtrado

Objetivo: eliminar ruido eléctrico y artefactos por movimiento.

- Filtro pasa-banda Butterworth, orden 4.
- Rango de frecuencias: 20–450 Hz.

Segmentación (Windowing)

Objetivo: evitar pérdida de información entre ventanas consecutivas.

- Tamaño de ventana: 4 segundos (~5036 muestras).
- Solapamiento: 50%.

Sincronización

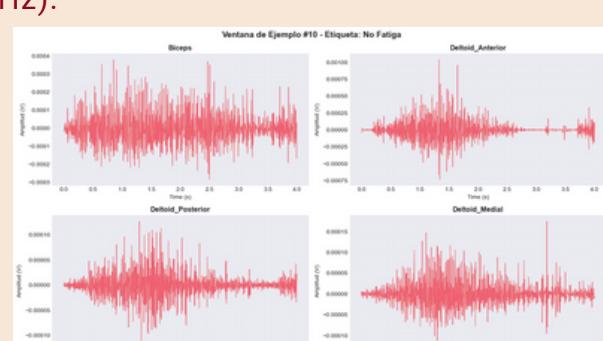
Objetivo: asignar a cada ventana el nivel correcto de fatiga.

- Se empareja con el índice de fatiga más cercano (50 Hz).

Balanceo de Clases (Binario)

Objetivo: evitar sesgo hacia clases mayoritarias.

- Uso de SMOTE para balancear las clases.



Extracción de características

Características calculadas por ventana:

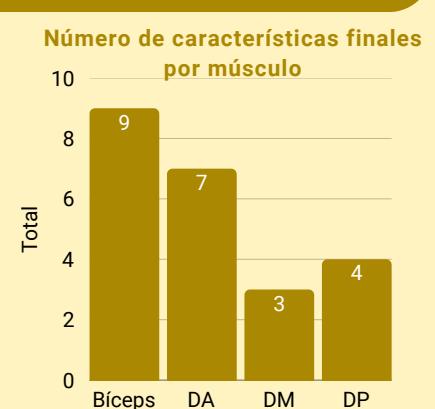
Inicial: Extracción de 208 características iniciales (52 por cada músculo).

Variance Threshold: Elimina características con baja variabilidad

208 → 102

SelectFromModel (Random Forest):

102 → 23



Características seleccionadas para el modelo

Canal	Features Seleccionadas
Bíceps	ZC, SSC, KURT, MNF, POWER_LOW, POWER_RATIO_LOW_HIGH, POWER_STD, MFL, ENTROPY
Deltoides Anterior (DA)	ZC, SSC, WL, KURT, MNF, POWER_RATIO_LOW_HIGH, MFL
Deltoides Medio (DM)	ZC, SSC, POWER_RATIO_LOW_HIGH
Deltoides Posterior (DP)	ZC, SSC, MFL, ENTROPY

Modelos Multiclasificación

- Random Forest
- XGBoost
- SVM (Support Vector Machine)
- Gradient boosting
- Voting Classifier (Soft Voting)
- Stacking Classifier

Modelos Binarios

- XGBoost Binary
- Random Forest Binary
- SVM Binary

Clase 0 (NO FATIGA): Nivel Baja
Clase 1 (FATIGA): Niveles Media + Alta

Train Set:
Clase 0 (NO FATIGA): 5,365 (34.04%)
Clase 1 (FATIGA): 10,396 (65.96%)

SMOTE

Train Set:
Clase 0 (NO FATIGA): 10,396 (50.00%)
Clase 1 (FATIGA): 10,396 (50.00%)

División de datos en:

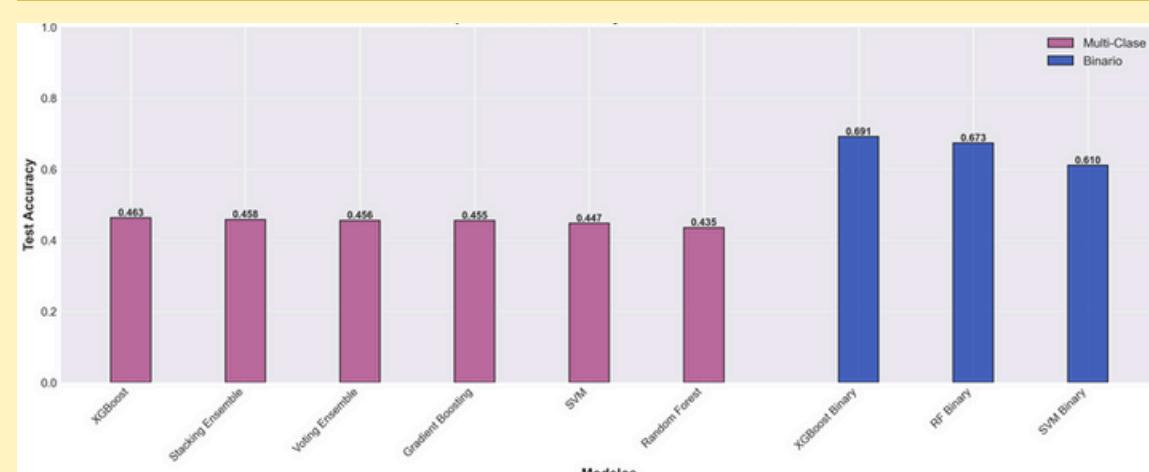
- Entrenamiento: Sujetos 1-8 (70%)
- Validación: Sujetos 9-11 (15%)
- Prueba: Sujetos 12-13 (15%)

Tabla comparativa de hiperparámetros importantes en modelos multi-clasificación y binario

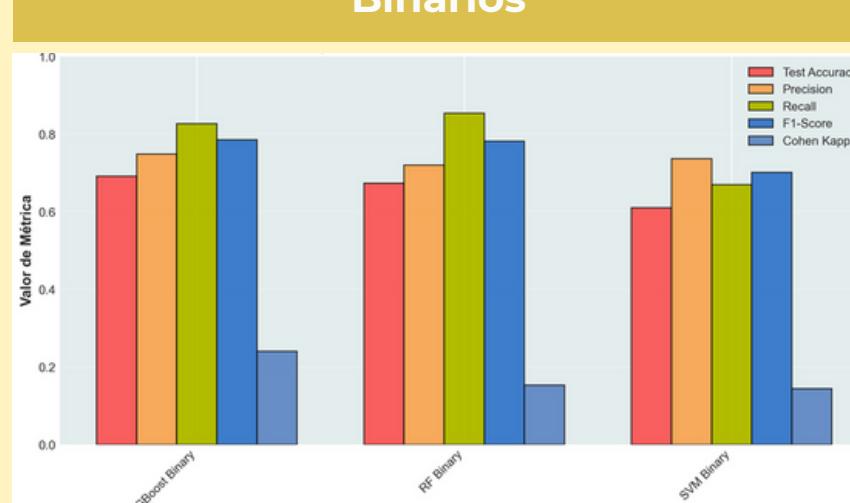
Hiperparámetro	Multi-clase	Binario
n_estimators	500	300
max_depth	8	7
learning_rate	3	5
min_child_weight	—	3
eval_metric	mlogloss	logloss

RESULTADOS

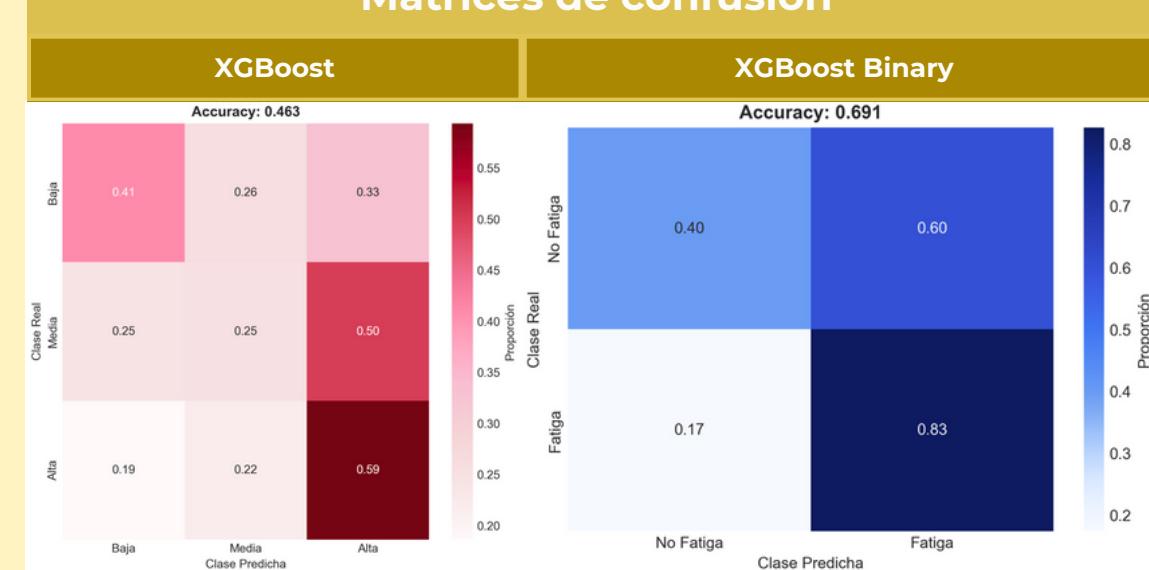
Comparación de Accuracy



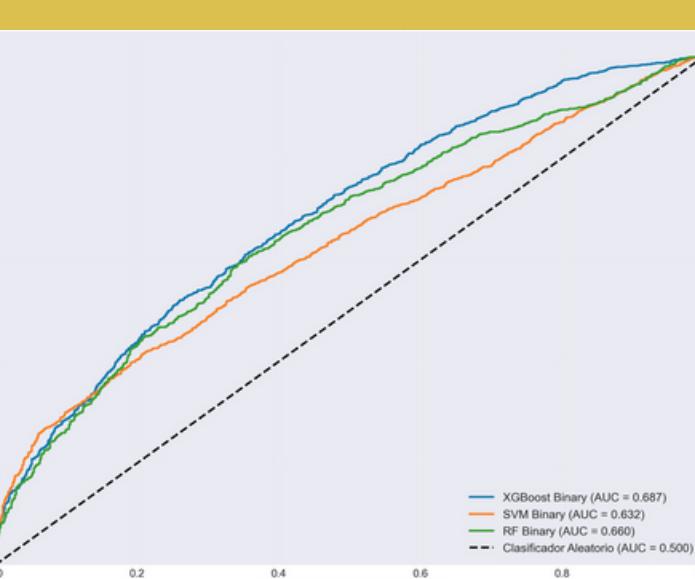
Comparación de Métricas - Modelos Binarios



Matrices de confusión



Curvas ROC - Modelos Binarios



CONCLUSIONES

- A pesar de intentar clasificar tres niveles de fatiga, los resultados demostraron que simplificar el modelo a un **enfoque Binario (Fatiga Sí/No)** mejora drásticamente la precisión del sistema.
- El algoritmo **XGBoost binario** se consolidó como la estrategia más robusta, superando significativamente a los enfoques multicategoría en fiabilidad y rendimiento.

Limitaciones

- Solo 13 sujetos (limitado para DL)
- Limitado a brazo (4 canales EMG por trial)
- 12 trials por sujeto con duraciones variables
- Split aleatorio (no por sujetos) en modelo binario
- Posible sesgo hacia características específicas de individuos

Recomendaciones

- Evaluar uso de Deep Learning (CNN- LSTM)
- Re-entrenar con split por sujetos (validación LOSO)
- Validación clínica en +50 sujetos
- Hacer análisis más detallados y manuales a cada característica a considerar

BIBLIOGRAFÍA

- [1] Musculoskeletal health, Who.int. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/musculoskeletal-conditions>. [Accessed: 02-Dec-2025].
- [2] J. Lucas, P. van Doorn, E. Hegedus, J. Lewis, and D. van der Windt, "A systematic review of the global prevalence and incidence of shoulder pain," *BMC Musculoskelet. Disord.*, vol. 23, no. 1, p. 1073, 2022.
- [3] M. Krisstell et al., "PREVALENCIA DE DOLOR MUSCULOSQUELÉTICO EN DOCENTES DE NIVEL PRIMARIA Y SECUNDARIA QUE REALIZAN TRABAJO REMOTO EN LA INSTITUCIÓN EDUCATIVA LEONARD EULER EN LIMA-PERÚ 2021 Prevalence of musculoskeletal pain in primary and secondary level teachers who perform remote work at the Leonard Euler Educational Institution in Lima, Peru" Edu.pe. [Online]. Available: https://repository.upch.edu.pe/bitstream/handle/20.500.12866/13190/Prevalencia_SanchezTueros_Marjorie.pdf?sequence=1&isAllowed=y. [Accessed: 02-Dec-2025].
- [4] Researchgate.net. [Online]. Available: https://www.researchgate.net/publication/269104978_The_Usefulness_of_Mean_and_Median_Frequencies_in_Electromyography_Analysis. [Accessed: 02-Dec-2025].
- [5] Z. Feng, Y. Wang, and L. Liu, "Muscle fatigue detection method based on feature extraction and deep learning," in 2022 7th International Conference on Intelligent Computing and Signal Processing (ICSP), 2022, pp. 97–100.